МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)
Институт №8 «Компьютерные науки и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №3
по курсу «Программирование графических процессоров»
Классификация и кластеризация изображений на GPU.

Выполнил: М.С.Гаврилов
Группа: 8О-406Б
Преподаватели: К.Г. Крашенинников,
А.Ю. Морозов

Москва,2022

Условие

Цель работы. Научиться использовать GPU для классификации и кластеризации изображений. Использование *константной памяти* и *одномерной сетки потоков*.

Вариант 2. Метод расстояния Махаланобиса.

Программное и аппаратное обеспечение

Характеристики графического процессора	
Compute capability:	7.5
Name:	NVIDIA GeForce GTX 1650
Total Global Memory:	4102029312
Shared memory per block:	49152
Registers per block:	65536
Warp size:	32
Max threads per block:	(1024, 1024, 64)
Max block:	(2147483647, 65535, 65535)
Total constant memory:	65536
Multiprocessors count:	14

Процессор: Intel(R) Core(TM) i5-11260H @ 2.60GHz
Оперативная память: 7875 Мб
Накопитель: kimtigo SSD 256GB

OS: Linux Mint 21
IDE: Visual Studio Code 1.72.0
compiler: Cuda compilation tools, release 11.8, V11.8.89

Метод решения

Для хранения и обработки изображений используется класс image. Для работы с пикселями используется класс pixel. Этот класс — обертка над классом uchar4, реализующая методы записи и чтения из файла, а также вывода на экран. Пиксели изображений хранятся в одномерном массиве. При выполнении алгоритма классификации для уменьшения времени доступа используется текстурная память в двумерном массиве. Чтобы большие изображения умещались в текстурную память, использует двумерная текстура, а перед копированием изображение балансируется так, чтобы длины его сторон не сильно отличались. При работе ядра результат записывается в глобальную память и, по завершении, помещается на место изначальных пикселей изображения. В ядре каждый поток выполняет расчет расстояния соответствующих пикселей до каждого из классов методом Махаланобиса и определяет класс, к которому они принадлежат.

Описание программы

Программа состоит из одного файла, в котором реализованы классы pixel и image, написано ядро и функция main. Класс image, будучи унаследованным из л.р.2, помимо классификации, по-прежнему может выполнять сглаживание SSAA.

Основные методы двух перечисленных выше классов:

Класс pixel

Имеет один член — значение (uchar4)

Метод	Описание
pixel(char red,char green, char blue, char alpha)	Конструктор, создает пиксель с заданными значениями каналов.
pixel read_from_file(std::ifstream& in)	Считывает пиксель в формате, описанном в задании к л.р. из файла и записывает его в себя.
pixel print_to_file(std::ofstream& out)	Записывает себя в файл в формате, описанном в задании к л.р.
void print()	Выводит в stderr значение каждого канала
void print_avg()	Выводит stderr среднее значение цветовых каналов

Класс image

Имеет 3 члена — Ширина, Высота и Указатель на массив, в котором лежат пиксели.

Метод	Описание
image(int w_,int h_, pixel* array)	Создает изображение размером w*h с пикселями, хранящимися в arrray
image(std::string in_adress)	Считывает изображение из файла в формате, описанном в задании
int SSAA(int new_w, int new_h, int block_dim, int thread_dim)	Выполняет сжатие SSAA на GPU.
void Classify(std::vector<std::vector<int> >> class_coords)	Выполняет классификацию методом расстояний Махаланобиса на GPU.
void print_to_file(std::string filename)	Записывает изображение в файл в формате, описанном в задании
void print_visual(	Выводит на экран усредненные значения цветовых каналов всех пикселей в сетке со сторонами w и h

void print()	Выводит в stderr значения всех каналов всех пикселей

Ядро

```
__global__ void kernel(cudaTextureObject_t pix, int size_w, int size_h , int coef_w, int coef_h,
pixel* res)
```

Перед запуском ядра выполняется расчет средних значений и обратных матриц ковариации для каждого класса и помещение оных в константную память. Так как не все изображения из поддерживаемого диапазона размеров могут уместиться в текстурной памяти, ядро последовательно применяется к частям изображения в 100 000 000 пикселей.

Результаты

1. Сравнение времени работы ядра с различными конфигурациями.

Количество примеров на класс в каждом тесте одинаково и равно 1000, так как обработка примеров выполняется вне ядра.

Размер файла 1 000 x 1 000 pix

Размерность ядра	Время работы (мс)
<<<1,32>>>	243.279
<<<32,32>>>	14.4843
<<<32,1024>>>	10.5372
<<<64,64>>>	10.655
<<<512,512>>>	9.5369
<<<1024,1024>>>	9.6189

Размер файла 10 000 x 10 000 pix

Размерность ядра	Время работы (мс)
<<<32,1024>>>	1499.98
<<<32,64>>>	1522.25
<<<64,64>>>	1476.44
<<<512,512>>>	1369.29
<<<1024,1024>>>	1340.36

Размер файла 100 000 x 100 000 pix

Размерность ядра	Время работы (мс)
<<<64,64>>>	
<<<512,512>>>	
<<<1024,1024>>>	

2. Сравнение времени работы CPU и ядра (конфигурация <<64 64>>)

Размер теста	Время на CPU (мс)	Время на GPU (мс)
1 000 x 1 000 pix	4179	10.5969

3. Примеры работы программы

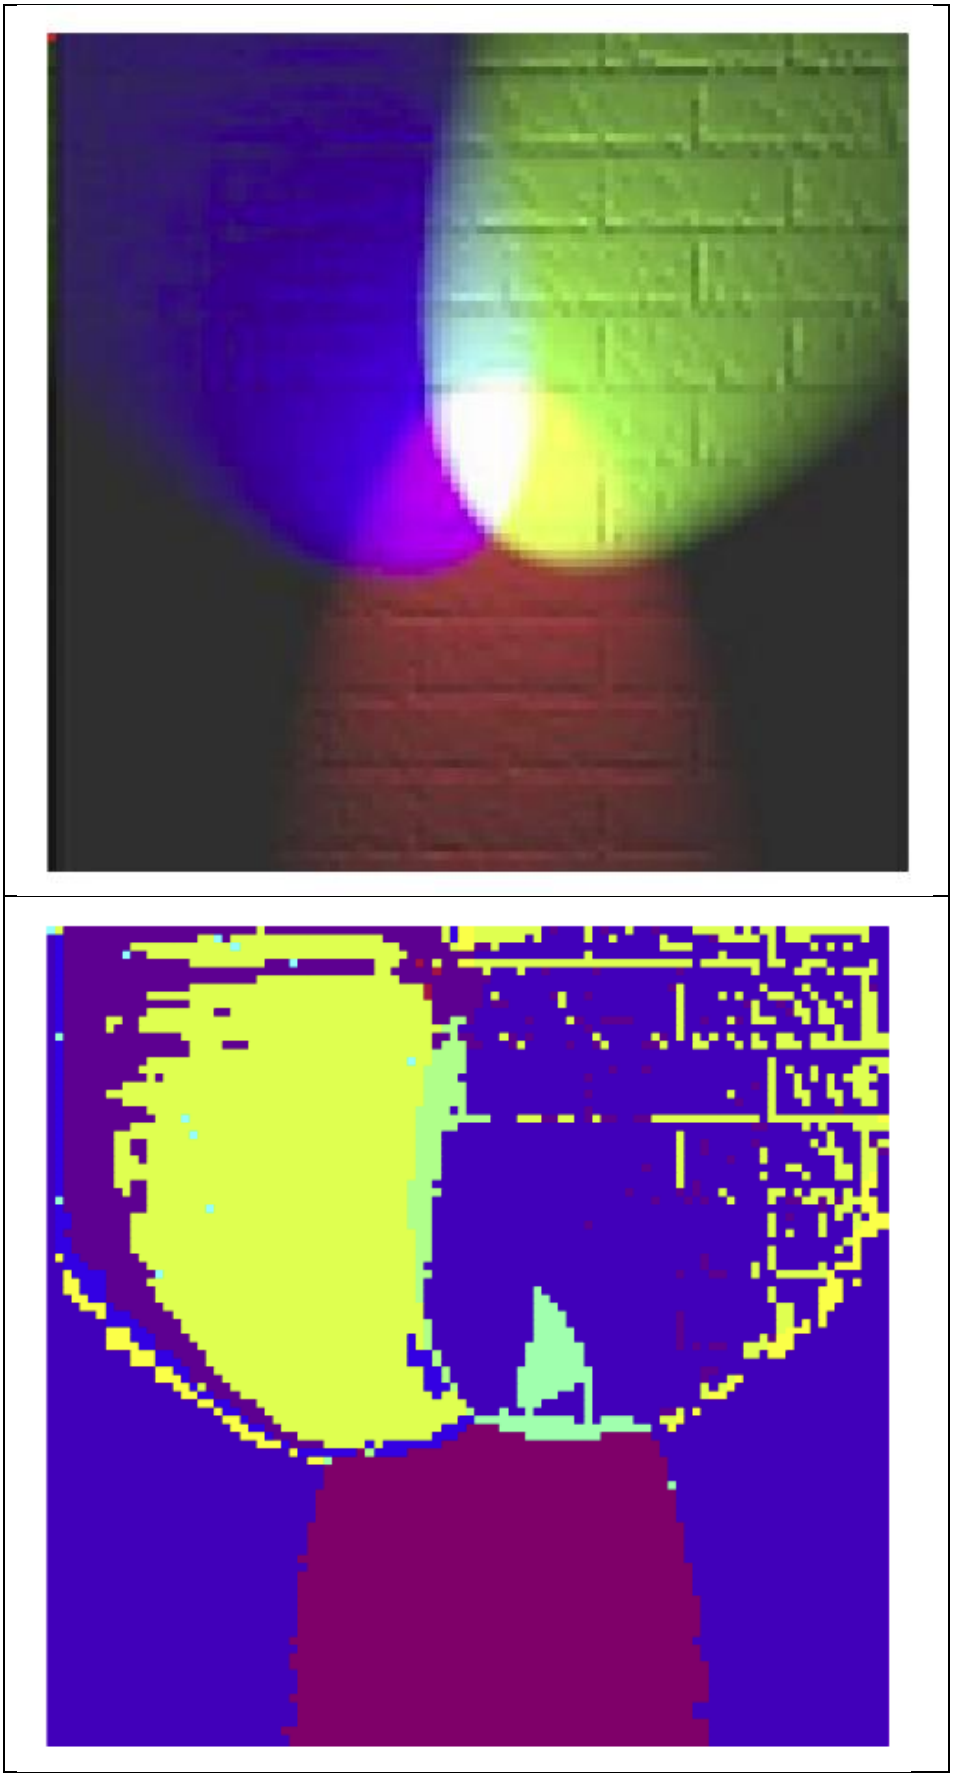

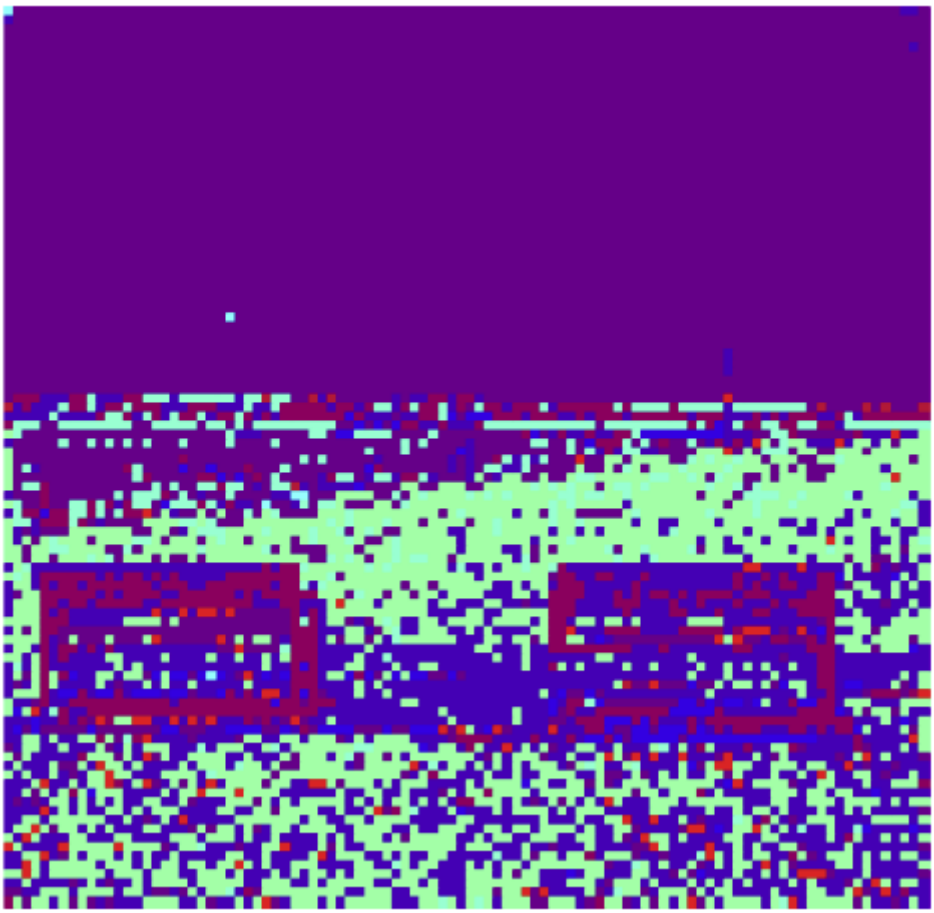

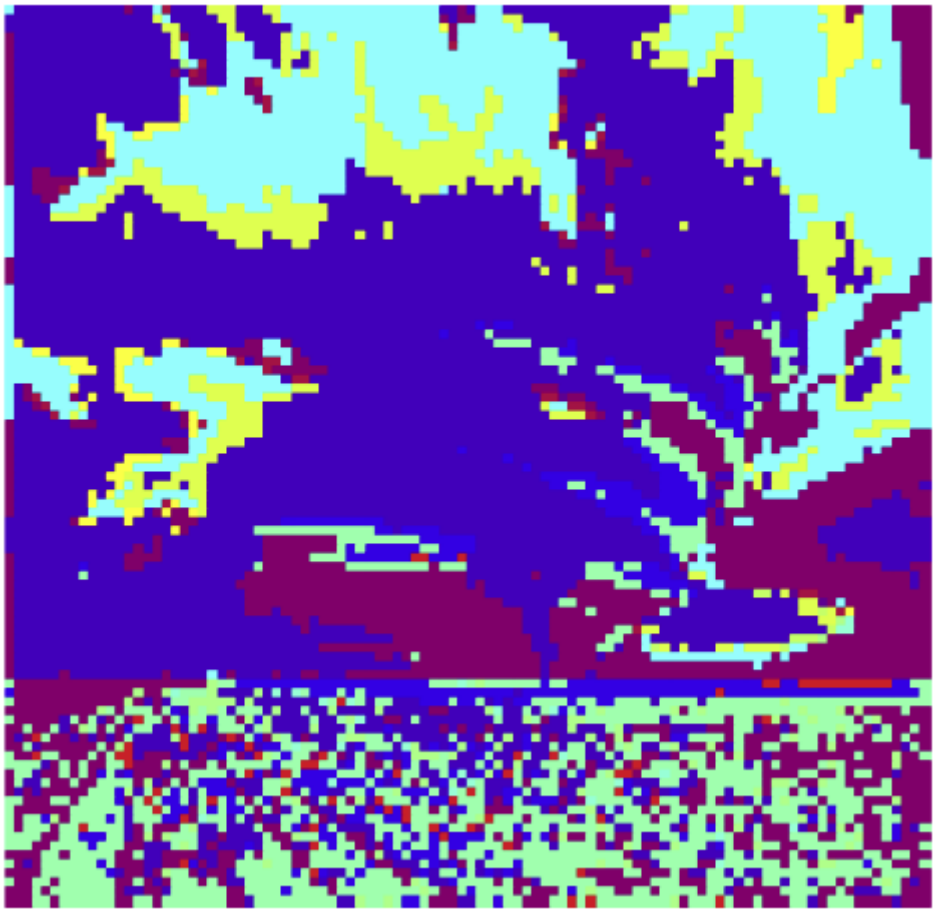

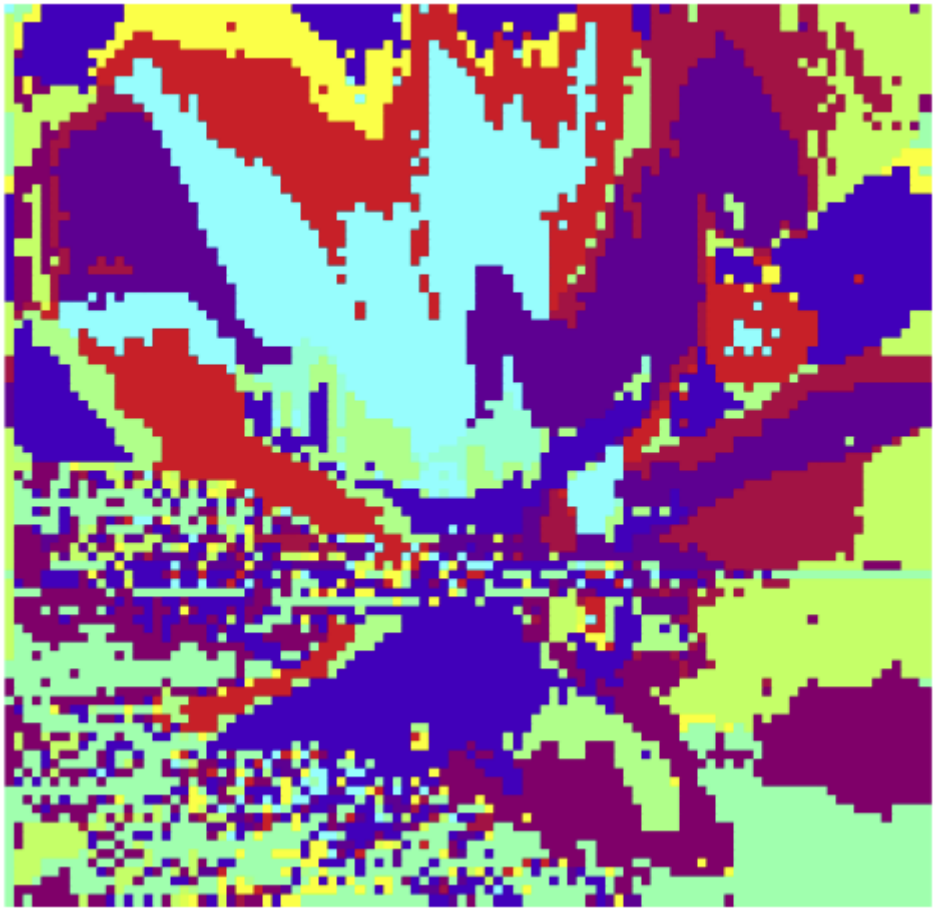

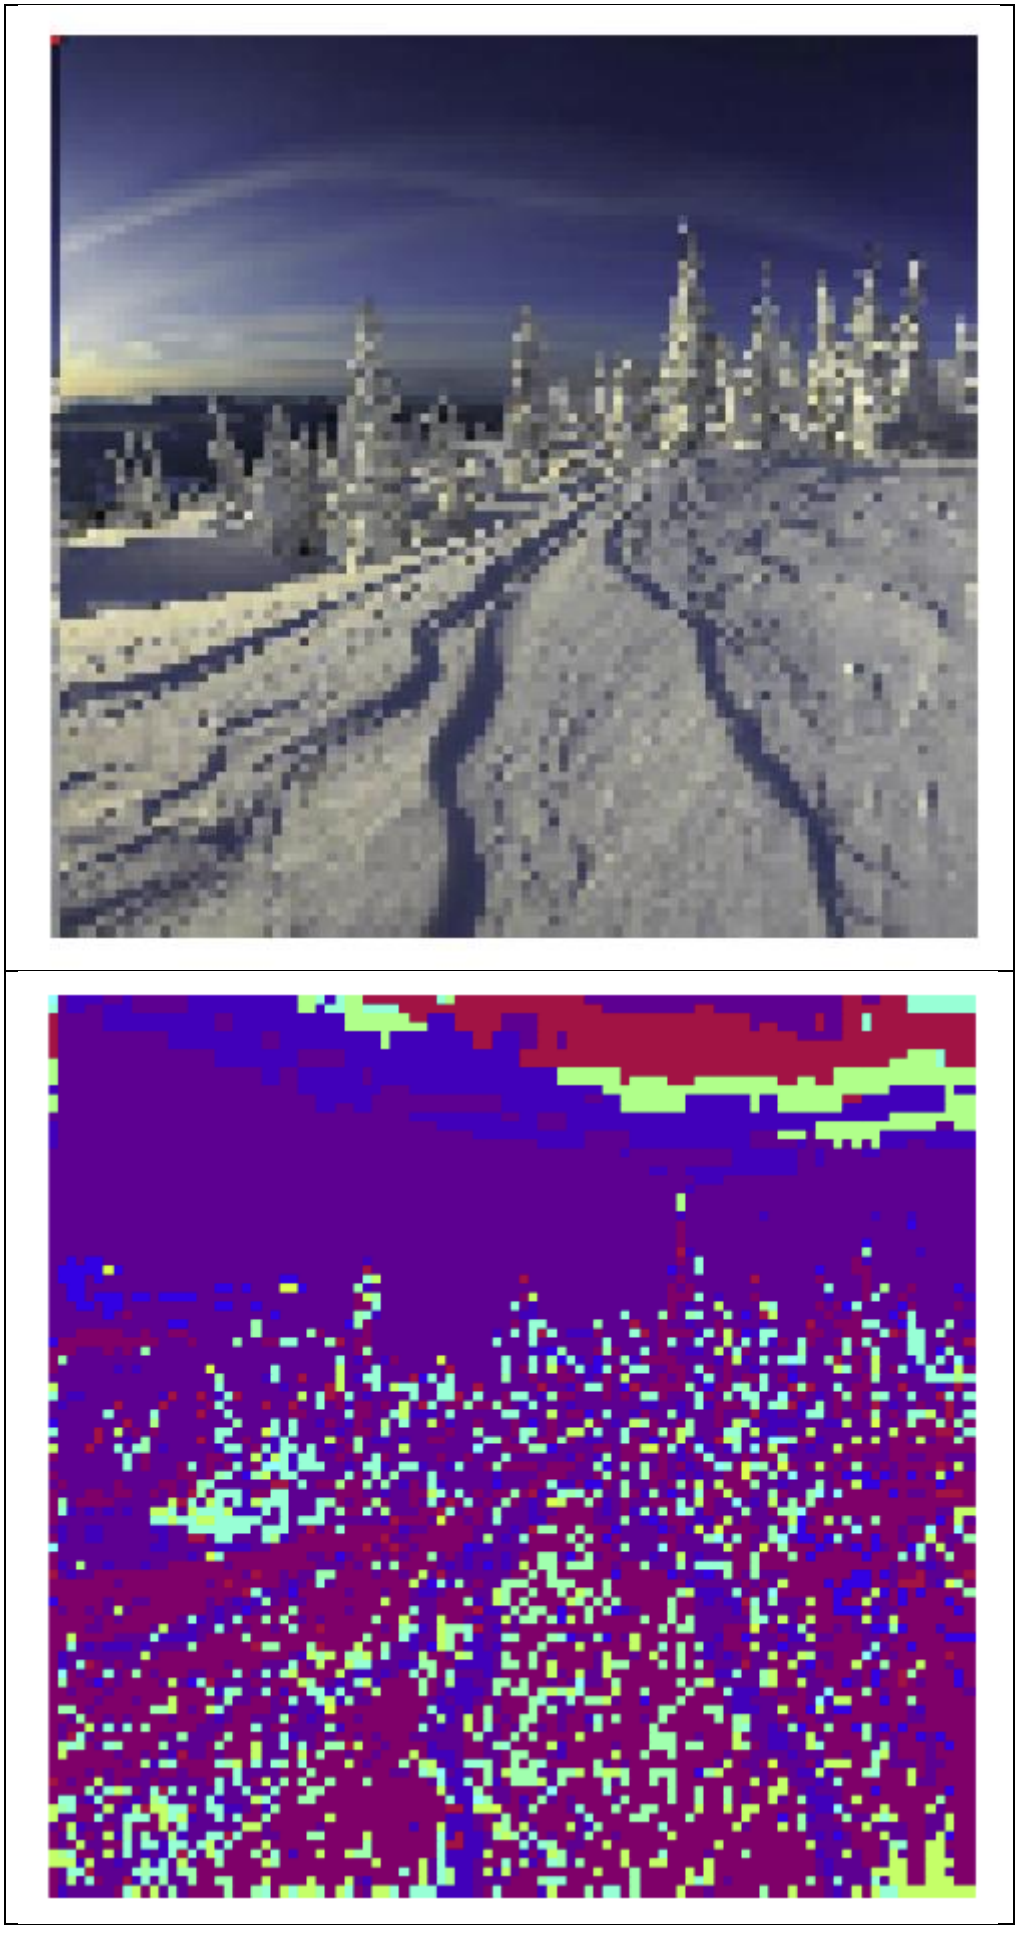

Вывод

В ходе выполнения этой лабораторной работы, я ознакомился с методами классификации пикселей изображения, допускающими распараллеливание, и реализовал метод расстояний Махаланобиса, который имеет применения в области машинного обучения. Я получил опыт работы с константной памятью в среде CUDA.

Также я понял, что иногда проще и эффективнее использовать глобальную память, даже несмотря на то, что обработка текстур уже реализована и, казалось бы, совсем немного осталось изменить. Помимо этого, оказывается, программа, хранящая расстояния в интах, а не даблах может дожить до 20-го теста на чекере, что весьма вводит в заблуждение относительно причин ее поломки на оном.

Версия на мультипроцессоре, разумеется, оказалась быстрее, чем на CPU, уменьшение затраченного времени при увеличении размерности сетки также наблюдалось, хотя вообще время затрачивалось больше, чем в л.р.2, что, вероятно, связано с большим количеством операций в ядре.